

Василенко Егор Викторович

Желаемая должность: Стажёр Data Scientist / ML-инженер / Аналитик данных

+7 (996) 776-80-37 | egor.vasilenko.2004@yandex.ru
@oknelisavroge | github.com/KsyLight | Санкт-Петербург

НАВЫКИ

Языки программирования: Python, SQL

Python / ML stack: Pandas, NumPy, scikit-learn, CatBoost, XGBoost, PyTorch

Классическое машинное обучение: задачи классификации, регрессии и кластеризации (деревья решений, случайный лес, градиентный бустинг, KNN, SVM и другое)

Глубокое обучение: базовые архитектуры нейронных сетей (CNN, RNN, трансформеры), дообучение эмбединговых моделей, применение эмбединговых и LLM-моделей в RAG-системах и агентных сценариях

Оценка и настройка моделей: подбор и интерпретация метрик качества, валидация моделей, подбор гиперпараметров

Базы данных и обработка данных: PostgreSQL, ClickHouse, базовые знания PySpark

Прикладные методы: анализ данных, анализ временных рядов, эконометрика, A/B-тестирование

Математика: теория вероятностей, математическая статистика, методы оптимизации, линейная алгебра, математический анализ

Другое: Git, Docker, работа с окружением, английский язык — B1

ОПЫТ РАБОТЫ

ООО «Газпромнефть ИТО»

октябрь 2025 – март 2026

Стажёр ML-инженер

Санкт-Петербург

- Разрабатывал RAG-сервис для поиска и ответа по внутреннему реестру проектов.
- Работал с задачей поиска по текстовым и частично структурированным данным, включая проектную информацию, статусы, описания и дополнительные атрибуты.
- Стек: Python, эмбединговые модели, rerank модели, LLM, LangChain, Pydantic, Streamlit, ChromaDB, BM25.

ОБРАЗОВАНИЕ

Санкт-Петербургский государственный экономический университет

2022 – 2026

Факультет экономики, финансов и информационных технологий

Санкт-Петербург

- Профиль: математическое моделирование и анализ данных в экономике.
- ВКР: разработка сервиса интеллектуального поиска проектной информации на основе методов анализа текстовых и частично структурированных данных.

ДОПОЛНИТЕЛЬНОЕ ОБРАЗОВАНИЕ

Школа аналитиков данных МТС

2024 – 2025

- Участник и выпускник Школы Аналитиков Данных от МТС по Data Science. Сертификат можно найти на GitHub.
- Блоки Python, SQL, ML, NN, BigData и другие, а также итоговый проект по антифроду (классификация + кластеризация разговоров).

Аналитик данных расширенный, Яндекс Практикум

2024 – 2025

- Курс про аналитике данных с треком в продуктовую аналитику. Сертификат можно найти на GitHub.

ДОСТИЖЕНИЯ

Всероссийский кейс-чемпионат «ProЦифру»

2025

- 1 место в секции от «Газпром нефти» по глубокому машинному обучению. Реализовали сервис для HR с дообученной по массиву резюме xlm-roberta на многоклассовую классификацию.

Cup IT 2025, направление «Анализ данных»

2025

- Топ-15% участников, 12 место.

ПОРТФОЛИО / ОСНОВНЫЕ ПРОЕКТЫ

RAG, LLM и агентные системы

RAG-сервис интеллектуального поиска проектной информации

2025 – 2026

- Проект в рамках работы в ООО «Газпромнефть ИТО» и ВКР: сервис для поиска и анализа проектной информации во внутреннем реестре проектов.
- Работал с частично структурированными Excel-данными: проектные описания, статусы, атрибуты, идентификаторы и дополнительные поля.
- Реализовывал пайплайн подготовки данных, генерации текстовых фрагментов, гибридного поиска, ранжирования и формирования ответа с опорой на найденные источники.
- **Стек:** Python, Pandas, OpenPyXL, embeddings, ChromaDB, BM25, LangChain, rerank models, LLM, Pydantic, Streamlit.

Мультиагентная база знаний для статей и конспектов

в процессе

- Pet-проект: система для загрузки ссылок, PDF-файлов и заметок, их структуризации и сохранения в виде связанной базы знаний.
- Основная идея — не просто хранить статьи, а строить тематический граф: родительские и дочерние темы, связи между статьями, авторами, тегами и конспектами.
- Планируется агентная архитектура: отдельные агенты для извлечения структуры, краткого пересказа, выделения терминов, поиска связей и работы с Obsidian.
- **Планируемый стек:** Python, LLM, embeddings, vector database, graph database, Obsidian, MCP / API-интеграции.

NLP и прикладные ML-проекты

Streamlit-приложение для анализа резюме по матрице Альянса ИИ

2025

- Командный проект для кейс-чемпионата «ProЦифру»: сервис для анализа соответствия компетенций IT-специалистов требованиям рынка.
- Обработали более 700 резюме: выполнили извлечение текста, разметку и подготовку словаря компетенций.
- Дообучали модель семейства RoBERTa для работы с компетенциями и реализовали Streamlit-приложение.
- Приложение было развернуто на арендованном сервере с HTTPS и Docker; команда заняла 1 место в секции от «Газпром нефти».

Антифрод-проект по классификации и кластеризации мошеннических разговоров

2024 – 2025

- Итоговый проект в Школе аналитиков данных МТС, который позже развивал в рамках курсовой работы.
- Самостоятельно собирал данные мошеннических разговоров: частично парсил открытые источники и дополнительно генерировал синтетические примеры.
- Дообучал эмбединговую модель для классификации текстов, проводил кластеризацию разговоров и анализировал полученные группы.
- **Стек:** Python, NLP, embeddings, PyTorch, scikit-learn, clustering, Pandas.

Классическое машинное обучение

Регрессия стоимости аренды жилья

2024 – 2025

- Решал задачу регрессии: обработка пропусков, логарифмирование целевой переменной, извлечение признаков из дат, кодирование категориальных признаков.
- Обучал CatBoostRegressor, подбирал гиперпараметры через Optuna, анализировал качество по RMSE, MSE и R^2 .
- Использовал визуализацию остатков и SHAP для анализа важности признаков; занял 1 место в Kaggle-соревновании.
- **Стек:** Python, Pandas, scikit-learn, CatBoost, Optuna, SHAP, Statsmodels.

Стекинг регрессионных моделей с оценкой неопределённости

2024 – 2025

- Проводил EDA: анализ распределений, выбросов, корреляций, дублей и качества признаков.
- Собрал preprocessing pipeline через ColumnTransformer: обработка дат, логарифмирование, кодирование и масштабирование признаков.
- Сравнивал CatBoost, LightGBM, XGBoost, RandomForest и Ridge; реализовал стекинг через мета-модель.
- Дополнительно рассчитывал алеаторную, эпистемическую и total-неопределённости, анализировал ошибку модели относительно доверия.
- **Стек:** Python, scikit-learn, CatBoost, LightGBM, XGBoost, Optuna, SHAP.